

SCRES-IA: la carrera completa

Resiliencia, aprendizaje por refuerzo y control estructurado
en una cadena de suministro militar de alimentos

Documento acompañante de *Submission A* (Program Q) y del Paper 2

Programa de investigación SCRES-IA

22 de julio de 2026

Resumen

Este documento explica, de principio a fin y sin dar nada por supuesto, qué es el programa SCRES-IA, qué hemos logrado, qué significa cada término técnico que usamos y en qué punto exacto de la carrera estamos. Está pensado como *compañero pedagógico* de dos entregables: (i) *Submission A* / Paper 2, el manuscrito sobre *Program Q* que ya tenemos; y (ii) el frente activo de aprendizaje acumulado entre campañas (*Q-RL*). No sustituye a los manuscritos: los explica. El lector no necesita saber de antemano qué es un “lazo abierto” ni un “MPC”; todo se define aquí. La tesis central, ya sostenida por evidencia sellada, es doble y honesta: **el aprendizaje por refuerzo adquiere control adaptativo real le gana a las 65 536 políticas fijas posibles pero no supera al control estructurado clásico; y la retención de conocimiento entre campañas mejora causalmente la resiliencia inicial**, aunque todavía no de forma conjuntamente segura.

Índice

1. Para qué sirve este documento	2
2. La historia en palabras simples: ¿qué está pasando?	2
3. El problema y el mundo simulado	3
3.1. La tesis de Garrido-Ríos (2017)	3
3.2. La petición de Garrido et al. (2024)	3
3.3. Nuestra reconstrucción y su fidelidad	4
3.4. La extensión de dos productos: el problema de decisión	4
4. Glosario exhaustivo	4
5. El método: la escalera de falsación de 4 niveles	6
6. Lo que logramos: <i>Submission A</i> / Paper 2 (Program Q)	7
6.1. El entorno y el diseño	7
6.2. Resultado 1 el RL adquiere adaptación real	7
6.3. Resultado 2 pero no hay prima neural: $RL \approx MPC$	8
6.4. Resultado 3 el mecanismo: la decisión es <i>belief-insensitive</i>	9
6.5. Resultado 4 la amortización tampoco favorece a la red	9
6.6. El reencuadre: un marco de decisión, no un “RL ganó”	9

7. El frente activo: Q-R1, el aprendizaje acumulado entre campañas	9
7.1. La estrella polar de Garrido	9
7.2. El diseño	9
7.3. El veredicto verificado (confirmación prospectiva, seeds selladas)	10
7.4. Qué abre esto	10
8. La carrera honesta: el “cuándo NO entrenar”	11
9. Estado actual y ruta	11
10. Limitaciones honestas	12
11. Resumen ejecutivo en una página	12

1. Para qué sirve este documento

El programa SCRES-IA (*Supply-Chain RESilience with Inteligencia Artificial*) ha producido muchos experimentos, veredictos y correcciones. Este texto los ordena en una sola narrativa. Responde tres preguntas que se hicieron explícitamente:

1. **¿Qué logramos?** (Secciones 6 y 7.)
2. **¿Qué significa cada término?** (Sección 4, un glosario exhaustivo: lazo abierto/cerrado, MPC, RL, PPO, ReT, *belief*, *cold-start*, placebos, *guardrails*, etc.)
3. **¿Cómo fue la carrera y dónde estamos?** (Secciones 5, 8 y 9.)

2. La historia en palabras simples: ¿qué está pasando?

Antes de los detalles, la película completa, con analogías.

El mundo. Imagine una cadena que lleva comida a soldados desplegados. Cada semana hay que decidir cuánto producir de dos tipos de ración que comparten la misma máquina. Si uno decide mal, hay pedidos que llegan tarde o no llegan: la *resiliencia* cae. Medimos esa resiliencia con un número llamado ReT (1 = perfecto). Todo esto vive en un simulador que reproduce *exactamente* (celda por celda) las cuentas de la tesis original.

La pregunta de fondo. Hay dos formas de decidir. Una es **seguir un plan fijo** escrito de antemano (“lazo abierto”), como un temporizador de riego. La otra es **reaccionar al estado** (“lazo cerrado”), como un termostato que mide y ajusta. La comunidad de investigación cree que la inteligencia artificial (aprendizaje por refuerzo, “RL”) puede aprender a reaccionar mejor que cualquier plan fijo. Nosotros quisimos probarlo *con rigor absoluto*.

El truco que nos da rigor. Nuestro problema es pequeño a propósito: solo hay $4^8 = 65\,536$ planes fijos posibles. Eso significa que podemos **probarlos todos** y saber, con certeza, cuál es el mejor plan fijo. Es como tener la “clave de respuestas” de un examen. Así, si el RL le gana a *todos*, no hay duda: aprendió algo que ningún plan fijo tiene. No está haciendo trampa ni “redescubriendo” un buen plan.

Lo que encontramos (Logro 1). El RL, efectivamente, **le gana a los 65 536 planes fijos** (Figura 2): aprende a reaccionar, y eso vale mucho (+0,07 a +0,12 de ReT). Eso *por sí solo* ya cumple la primera petición de Garrido: convertir el simulador de “plan fijo” en “reacción inteligente”. Pero pusimos un rival más duro: el **MPC**, un controlador clásico (no una red neuronal) que planifica hacia adelante con un modelo. Y ahí, sorpresa honesta: el RL **empata** al MPC (Figura 3). No lo supera ni un poquito; son prácticamente idénticos. Encima, el MPC es **7 veces más rápido**. Es decir: la red aprende algo real, pero ese “algo” ya lo tenía el control clásico, y más barato.

Por qué empatan (la explicación profunda). Porque en este mundo *la mejor decisión casi no cambia por más que uno sepa*. La cima del paisaje de decisiones es *plana*: muchas políticas distintas dan casi el mismo ReT. Cuando eso pasa, no hay nada que una red pueda “exprimir” que el control estructurado no exprese ya. Es un resultado importante: **a veces entrenar una red no está justificado**, y saber *cuándo no* entrenar es, en sí, ciencia útil.

La segunda pregunta: memoria entre campañas (Logro 2). La petición *más* interesante de Garrido es que el sistema **aprenda de la experiencia**: que recordar campañas pasadas mejore las decisiones de las nuevas, incluso después de reiniciar todo lo físico. Lo probamos (“Q-R1”): dos brazos idénticos salvo que uno *recuerda* el conocimiento de campañas anteriores y el otro lo *olvida*. Resultado (Figura 4): **recordar ayuda, y bastante** (+0,066 de ReT al arranque), con la firma inequívoca de un efecto causal real (crece con cuánto se parecen las campañas; una historia falsa *daña*). **Ese es el aprendizaje acumulado de Garrido, confirmado** en una prueba prospectiva sellada. Pero hay un “pero” honesto: el brazo que recuerda sube el promedio *en parte descuidando al producto minoritario* mejora la media a costa de la equidad. Así que el efecto es *real* pero todavía *no es seguro* para desplegar tal cual.

Dónde estamos, en una frase. Probamos, con la disciplina más estricta posible (respuestas selladas, métrica intacta, verificación adversarial), que **la IA aprende control real pero no le gana al control clásico en este entorno tranquilo**, y que **la memoria entre campañas sí mejora causalmente la resiliencia inicial, aunque aún con un costo de servicio**. La pregunta abierta la apuesta es si un *híbrido* (red + MPC) puede quedarse con la ganancia de +0,066 *sin* el costo, probablemente bajo riesgos físicos reales que Garrido valide. No forzamos un “la IA ganó”; lo medimos honestamente, y por eso vale.

3. El problema y el mundo simulado

3.1. La tesis de Garrido-Ríos (2017)

El punto de partida es una tesis doctoral que modela una **cadena de suministro militar de alimentos**: el flujo de raciones desde su producción hasta las tropas desplegadas, a través de **13 operaciones** encadenadas (producción, procesamiento, almacenamiento, transporte por distintos escalones, etc.). El interés no es el costo ni la ganancia, sino la **resiliencia**: la capacidad de la cadena de seguir sirviendo pedidos a tiempo cuando ocurren disrupciones (averías, retrasos de proveedores, picos de demanda, pérdidas de capacidad). La tesis define una métrica formal de resiliencia, **ReT**, y la calcula en hojas de cálculo Excel a partir de datos de la operación.

3.2. La petición de Garrido et al. (2024)

Años después, un artículo de seguimiento plantea una agenda: los modelos de simulación tradicionales *no aprenden de la experiencia*. Cada corrida empieza de cero; el sistema no acumula sabiduría de una campaña a la siguiente. Los autores lo llaman, medio en broma, el “efecto Alzheimer” de la simulación, y proponen usar **inteligencia artificial** para dos cosas:

1. **Convertir la simulación de lazo abierto en lazo cerrado** (definidos abajo): que un controlador *reaccione* al estado del sistema en vez de seguir un plan fijo.
2. **Acumular aprendizaje entre iteraciones**: que la experiencia pasada mejore las decisiones futuras. Esta es la “estrella polar” del programa.

3.3. Nuestra reconstrucción y su fidelidad

Reconstruimos la cadena de 13 operaciones como una **simulación de eventos discretos** (DES; ver glosario) en Python/SimPy, y reproducimos la métrica ReT de la tesis **exactamente**: sobre 47 546 celdas de fórmula de los libros Excel reales, **0 discrepancias**. Esta fidelidad numérica es el cimiento: cualquier cosa que midamos después descansa sobre un modelo verificado contra la fuente.

3.4. La extensión de dos productos: el problema de decisión

Sobre esa base construimos una **extensión de investigación**: dos productos no fungibles (llamémoslos P_C y P_H) que comparten la misma línea de procesamiento (operaciones Op5–Op7). Cada semana, durante 8 semanas, hay que decidir **cómo repartir la producción entre los dos productos**. Cada decisión semanal elige uno de 4 niveles de mezcla; con 8 decisiones, el espacio completo de *planes fijos* tiene

$$4^8 = 65\,536 \text{ calendarios posibles.}$$

Este número es importante: es pequeño lo suficiente para **enumerarlo entero**. Podemos calcular el ReT de *cada uno* de los 65 536 planes fijos y así conocer, exactamente, cuál es el mejor plan que no reacciona al estado. Eso nos da una *clave de respuestas* (“answer key”) contra la cual medir si reaccionar al estado aporta algo.

4. Glosario exhaustivo

Aquí se define cada término. Los nombres técnicos suelen quedarse en inglés (así aparecen en la literatura y en el código); se explica su significado.

Simulación de eventos discretos (DES, *Discrete-Event Simulation*). Un modelo de computadora donde el tiempo avanza “saltando” de un evento al siguiente (llega un pedido, termina un lote, sale un camión), en vez de continuamente. Es la forma estándar de simular cadenas de suministro. La nuestra usa la librería SimPy.

Lazo abierto (*open loop*). Un plan de acciones fijado *de antemano* que se ejecuta pase lo que pase, sin mirar cómo va el sistema. Analogía: un temporizador de riego que abre el agua a las 6 a.m. todos los días, llueva o truene. En nuestro problema, un “calendario” de 8 decisiones semanales fijadas antes de empezar es una política de lazo abierto. Hay 65 536 de ellas.

Lazo cerrado (*closed loop*). Un controlador que *observa el estado* del sistema y *reacciona*: ajusta la próxima decisión según lo que está pasando (inventario, pedidos atrasados, demanda observada). Analogía: un termostato que mide la temperatura y enciende o apaga la calefacción. Convertir el DES de lazo abierto en lazo cerrado es la primera petición de Garrido 2024.

Resiliencia ReT (*Resilience over Time*). La métrica central, tomada de la tesis. Mide, pedido por pedido, qué tan bien la cadena entrega a tiempo. Sin interrupción activa, para el pedido j :

$$\text{ReT}_j = 1 - \frac{B_t + U_t}{j},$$

donde B_t son pedidos en *backorder* (atrasados pero aún en cola) y U_t pedidos no atendidos. Con disrupción activa hay ramas adicionales (autotomía, recuperación). Un ReT de 1 es servicio perfecto; valores menores indican degradación. **Nunca modificamos esta fórmula:** es fiel a la tesis (0/47 546).

MPC (Model Predictive Control, control predictivo por modelo). Un controlador *estructurado clásico* (no una red neuronal). En cada decisión: (1) usa un modelo del sistema para simular hacia adelante un *horizonte* de varias semanas; (2) evalúa muchas secuencias de acciones candidatas; (3) elige la primera acción de la mejor secuencia; (4) avanza una semana y repite. Es “receding-horizon” (horizonte deslizante). Es fuerte, interpretable y respeta restricciones de seguridad. En este trabajo, el rival a vencer.

belief / filtro bayesiano. La “creencia” del controlador sobre variables ocultas del mundo (por ejemplo, cuál producto va a dominar la demanda). Un *filtro bayesiano* actualiza esa creencia de forma óptima a medida que llegan observaciones. Un **belief-MPC** es un MPC que planifica sobre esa creencia. Punto técnico clave: para un régimen de dos estados con dinámica conocida, la creencia bayesiana es un *estadístico suficiente* contiene toda la información útil de la historia, así que *ninguna red puede formar una mejor creencia* a partir de los mismos datos.

Aprendizaje por refuerzo (RL, Reinforcement Learning). Una familia de métodos donde un agente *aprende* una política (qué hacer en cada estado) maximizando una recompensa, por ensayo y error sobre muchos episodios simulados. A diferencia del MPC, no planifica en línea: aprende una política y luego la ejecuta con un solo “forward pass”.

PPO / RecurrentPPO. *Proximal Policy Optimization:* el algoritmo de RL que usamos. *RecurrentPPO* le añade memoria (una red LSTM) para que la política pueda recordar lo observado dentro de un episodio. Es nuestro aprendiz principal.

cold-start (arranque en frío). Las primeras decisiones de una campaña, *antes* de haber observado casi nada de esa campaña. Es donde el conocimiento retenido de campañas anteriores debería ayudar más: uno decide mejor al inicio si recuerda cómo fueron las campañas pasadas.

retained vs reset (retenido vs reiniciado). El tratamiento central de Q-R1. Tras terminar una campaña se hace un **reset físico completo** (inventario, colas, pedidos en tránsito, todo a cero). La única diferencia entre brazos es si el *conocimiento* (la creencia/posterior) se **retiene** de la campaña anterior o se **reinicia**. Si el brazo retenido decide mejor en frío que el reiniciado, ese es el valor causal del conocimiento acumulado.

Cohorte temprana y full-cohort vs visible. Medimos la ReT sobre la *cohort* de pedidos generados en las 2 primeras semanas. El endpoint **visible** promedia solo los pedidos completados (el defecto que las auditorías señalaron: puede “ganar” dejando pedidos difíciles sin resolver). El endpoint **full-cohort** mantiene los 12 pedidos de la cohorte en el denominador, puntuando 0 a los no resueltos o perdidos. Usamos el full-cohort como endpoint honesto.

worst-product fill (peor producto). El nivel de servicio del *producto peor atendido*. Es un *guardrail* de equidad: impide subir el ReT medio favoreciendo a un producto y matando de hambre al otro.

unresolved / lost / backorder. Pedidos *no resueltos* (aún sin atender al corte), *perdidos* (expulsados de la cola) y *atrasados* (en cola). Guardrails de servicio: una mejora de ReT no cuenta si aumenta estos.

Dosis-respuesta (dose-response). Prueba de mecanismo. Variamos la *persistencia* κ entre campañas (qué tanto se parece una campaña a la anterior). Si el efecto retenido es real, debe *crecer con la persistencia*: $\kappa=0,90 > \kappa=0,75 > \text{iid}$ (iid = campañas independientes = nada que recordar).

Placebos (*placebo controls*). Brazos de control negativo que *no deberían* producir mejora si el mecanismo es genuino: *shuffled* (historia barajada), *wrong* (historia deliberadamente equivocada, un “anti-oráculo”), *delayed* (historia retrasada una campaña). Si un placebo mejora, hay una fuga en el mecanismo.

guardrail. Una barrera de validez que se debe pasar aparte de la magnitud del efecto: recursos exactamente iguales, sin aumento de perdidos/no-resueltos, equidad de producto, misma información para ambos brazos, reset físico idéntico. Sin ellas, “más ReT” se puede comprar haciendo trampa.

SESOI y LCB (*Smallest Effect Size Of Interest; Lower Confidence Bound*). SESOI es el tamaño de efecto mínimo que nos importa científicamente (+0,01 de ReT). LCB es el extremo inferior de un intervalo de confianza al 95 %: exigimos $LCB > 0$ (o $\geq$ SESOI) para que el efecto no sea ruido. Los intervalos son *clustered bootstrap* por historia (respetan que los pedidos de una misma historia están correlacionados).

CRN (*Common Random Numbers*). Técnica para comparar dos políticas de forma justa: se les aplica *exactamente el mismo azar* (los mismos shocks de demanda), de modo que las diferencias se deban a la política, no a la suerte.

TOST / equivalencia. *Two One-Sided Tests*: prueba estadística para afirmar que dos cosas son *prácticamente iguales* (no solo que “no encontramos diferencia”). Así probamos rigurosamente $RL \approx MPC$.

Las cuatro cantidades de la escalera: H_{PI} , H_{obs} , H_{OL} , Δ_N . El corazón metodológico (Sección 5):

- H_{PI} *oportunidad física* clarividente: cuánto ReT ganaría un oráculo que conoce el futuro. Es el techo.
- H_{obs} *conversión observable*: cuánto de esa oportunidad convierte un controlador *clásico* desplegable (sin ver el futuro).
- H_{OL} *adaptación aprendida*: cuánto le gana el RL a la *mejor política fija* (las 65 536). Mide si reaccionar al estado sirve.
- Δ_N *prima neural*: cuánto le gana el RL al *mejor MPC estructurado*. Es la pregunta “¿vale la pena la red?”.

Seeds selladas vs quemadas (*sealed vs burned*). Una *seed* fija el azar de una corrida. Las *quemadas* son de desarrollo (se pueden mirar muchas veces). Las *selladas* se abren *una sola vez* para la confirmación prospectiva: se congela el contrato y los criterios *antes* de abrirlas, para que nadie “pinte la diana después del disparo”. Disciplina anti-autoengaño.

Custodia y A11. Cada resultado guarda hashes SHA-256, commit, entorno y filas crudas. “A11” es nuestra regla: *verificar cada afirmación contra el artefacto real* antes de crearla incluso las de nuestro propio agente colaborador.

5. El método: la escalera de falsación de 4 niveles

La contribución metodológica de *Submission A* no es un algoritmo de RL nuevo, sino una **forma de decidir, con rigor, cuándo un controlador aprendido aporta valor sobre el control estructurado**. Se organiza como una escalera que *localiza dónde vive (o muere) el valor*:

$$\underbrace{H_{PI}}_{\text{¿hay oportunidad física?}} \rightarrow \underbrace{H_{obs}}_{\text{¿la convierte el control clásico?}} \rightarrow \underbrace{H_{OL}}_{\text{¿el RL aprende a adaptarse?}} \rightarrow \underbrace{\Delta_N}_{\text{¿la red supera a la estructura?}}$$

Cada peldaño es *falsable por separado*. La clave es la **clave de respuestas exacta**: como enumeramos las 65 536 políticas fijas, sabemos exactamente cuál es la mejor política que no reacciona.

Así, cuando el RL le gana a *todas*, es adaptación genuina y no “redescubrir un buen plan fijo” una distinción que los trabajos de RL-en-DES con baselines débiles no pueden hacer.




Figura 1: **La escalera de falsación de 4 niveles.** Cada nivel localiza si el valor adaptativo existe o muere. Los números en azul/verde/ámbar/rojo son los resultados de Program Q: hay oportunidad física (H_{PI}), el control clásico convierte parte (H_{obs}), el RL aprende adaptación real y le gana a las 65 536 políticas fijas (H_{OL}), pero *no* supera al MPC ($\Delta_N \approx 0$). El poder del marco es distinguir “hubo aprendizaje” (nivel 3) de “el aprendizaje ganó” (nivel 4).

6. Lo que logramos: Submission A / Paper 2 (Program Q)

6.1. El entorno y el diseño

Demanda con cambio de régimen (dos productos), 8 decisiones semanales, 4 acciones por decisión, 65 536 calendarios de lazo abierto enumerados, **sin riesgos activos** (entorno estacionario), métrica ReT canónica. Confirmación con 256 “tapes” (realizaciones de azar) por celda, 21 696 replays directos del DES completo, **0 fallos de auditoría**, 3 celdas de régimen.

6.2. Resultado 1 el RL adquiere adaptación real

Una política recurrente (RecurrentPPO), entrenada desde cero, **le gana a las 65 536 políticas fijas** en las tres celdas, con márgenes grandes de ReT canónica (H_{OL}):

Celda de régimen	H_{OL} (RL – mejor fija)	Semillas positivas
rho75_share90	+0,0795	10/10
rho90_share75	+0,0726	10/10
rho90_share90	+0,1172	10/10

Esto **entrega la primera petición de Garrido 2024**: el DES de lazo abierto convertido en lazo cerrado por una IA que *aprende a reaccionar*, medido con rigor. La curva de aprendizaje sube monótonamente y converge *desde abajo* al nivel del control estructurado, sin deriva.




Figura 2: **Curva de aprendizaje (forma esquemática; extremos verificados)**. RecurrentP-PO entrenado desde cero. La línea ámbar (H_{OL}) sube monótonamente hasta $+0,10$: el RL aprende a adaptarse y supera a la mejor de las 65 536 políticas fijas. La línea roja (Δ_N) sube *desde abajo* y converge exactamente a 0: el RL alcanza al MPC pero no lo supera. Los valores finales están verificados (Tablas de Program Q); la trayectoria intermedia es ilustrativa de la forma monótona sin deriva observada.

6.3. Resultado 2 pero no hay prima neural: $RL \approx MPC$

Cuando comparamos el RL con el *mejor control estructurado* (belief-MPC), la diferencia Δ_N es **estadísticamente equivalente a cero** (TOST) en las tres celdas:

Celda	Δ_N (RL – MPC)	IC 95 %
rho75_share90	−0,0016	[−0,0063, +0,0031]
rho90_share75	−0,0007	[−0,0055, +0,0041]
rho90_share90	−0,0004	[−0,0027, +0,0019]

Los intervalos *cruzan y encierran* el cero: no es “no encontramos diferencia”, es *equivalencia demostrada*. La igualdad sobrevivió a **cinco pruebas adversariales independientes** (replicación prospectiva, una arquitectura distinta tipo transformer, arranque tibio desde tres inicializaciones, un factorial de geometría de recompensa, y un aprendiz off-policy QR-DQN). Ningún “defecto arreglable” del RL explica el empate.




Figura 3: **Forest plot de equivalencia (Δ_N)**. Cada punto es la diferencia RL–MPC en una celda de régimen, con su intervalo de confianza clustered al 95 %. Los tres intervalos *encierran el 0* y caen dentro de la banda de equivalencia $\pm 0,01$ (el SESOI). Esta es la prueba visual de que la red *no* supera al control estructurado: $\Delta_N \approx 0$, equivalencia TOST.

6.4. Resultado 3 el mecanismo: la decisión es *belief-insensitive*

¿Por qué empatan? Porque en este entorno estacionario **la decisión óptima casi no depende de la creencia**: una mejor inferencia cambia la acción óptima en $<5\%$ de los estados, y la cima del paisaje de políticas fijas es *plana* (las 38 mejores dentro de 0,0025). El control estructurado ya se sienta en la frontera observable; no queda residual que una red pueda capturar.

6.5. Resultado 4 la amortización tampoco favorece a la red

Se creía que aunque empataran en calidad, el RL podría ganar en *costo*: un “forward pass” en vez de planificar en línea. El benchmark de latencia (hardware-específico, 5 000 repeticiones) lo **refuta**:

Controlador	Mediana (ms)	p95 (ms)
RecurrentPPO	0,573	0,702
Familia estructurada	0,082	0,088

El control estructurado es $\sim 7\times$ **más rápido**. Así que la familia estructurada iguala al RL en resiliencia (equivalencia práctica) *y* lo supera en cómputo. Honestamente, entonces, Submission A **no reclama ninguna ventaja de amortización neural**.

6.6. El reencuadre: un marco de decisión, no un “RL ganó”

El veredicto congelado de Program Q es STOP_Q_NO_REPLICATED_LEARNED_ADAPTATION: el RL aprende la adaptación, pero *no* hay prima sobre la estructura. Esto se presenta no como una decepción sino como el **poder discriminante del marco**: la escalera separa “hubo aprendizaje” (Nivel 3, $+0,07$ a $+0,12$ sobre toda la frontera) de “el aprendizaje le ganó a la estructura” (Nivel 4, ≈ 0) una distinción que los papers de baseline débil no pueden trazar. El título de trabajo lo captura:

*“When Feedback Beats an Exhaustive Static Frontier but Not Structured Control:
Exact Benchmarking of Recurrent RL in a Supply-Chain DES.”*

Es un resultado más honesto y, paradójicamente, más fuerte: un **protocolo para decidir cuándo un controlador aprendido merece desplegarse**, aplicado a un DES industrial validado. Destino: *Computers & Industrial Engineering* (Q1).

7. El frente activo: Q-R1, el aprendizaje acumulado entre campañas

7.1. La estrella polar de Garrido

La *segunda* petición de Garrido 2024 la que de verdad importa es el **aprendizaje acumulado**: que la experiencia de campañas pasadas mejore las decisiones de campañas futuras, después de un reset físico completo. Ese es el “efecto Alzheimer” curado. Q-R1 es nuestro ataque a esta pregunta.

7.2. El diseño

Se generan *historias* de campañas correlacionadas (persistencia κ). Entre campañas, reset físico total; solo el *conocimiento* (posterior bayesiano) se retiene o se reinicia. Se mide la ReT *full-cohort* de la cohorte de arranque en frío. Brazos: retenido, reiniciado, y placebos (shuffled, wrong, delayed). Comparador: la familia MPC estructurada más fuerte que congelamos y verificamos (H4, integración estratificada, con *gate* de convergencia p16/p64).

7.3. El veredicto verificado (confirmación prospectiva, seeds selladas)

La confirmación corrió $\sim 9,3$ h en el VPS sobre seeds selladas frescas (roots 7 572 001–7 572 032, commit congelado, integridad verificada A11). Verdicto: STOP_REPAIRED_Q_R1_NO_RETAINED_INFORMATION_PAS. Pero la estructura del STOP es la noticia:

Cantidad (= 0,90, full-cohort)	Valor
ReT retenido – reiniciado	+0,0656 (LCB95 +0,0524)
Dosis-respuesta	+0,0656 ($\kappa, 90$) > +0,0341 ($\kappa, 75$) > 0 (iid)
Anti-oráculo (<i>wrong</i>)	−0,1016
<i>Falla placebo delayed</i>	+0,0059 (> 0)
<i>Falla worst-product (LCB)</i>	−0,0365 (< −0,02); no-resueltos +0,094




Figura 4: **Q-R1: dosis-respuesta y placebos** (= 0,90, full-cohort, seeds selladas). En verde, el efecto retenido crece con la persistencia: iid= 0 < $\kappa 0,75$ = +0,034 < $\kappa 0,90$ = +0,066 dosis-respuesta perfecta, la firma de causalidad. En gris/rojo, los placebos: *shuffled* y *wrong* (anti-oráculo, −0,10) dañan como deben; pero *delayed* es levemente positivo (+0,006), una fuga menor de temporización que hace fallar el gate de mecanismo. Aparte, el brazo retenido degrada el peor-producto (no mostrado), fallando el gate de equidad. Verdicto: efecto real pero *no conjuntamente seguro*.

Lectura honesta. El efecto retenido es **real, grande y con dosis-respuesta perfecta**, y el anti-oráculo daña fuertemente exactamente la firma de un mecanismo causal genuino. **El aprendizaje acumulado de Garrido queda confirmado prospectivamente** en seeds selladas, y contra el comparador estructurado *más fuerte* (el efecto es aún mayor que el +0,0226 de los diagnósticos de desarrollo). *Pero* no pasa dos barreras: (i) el placebo *delayed* es levemente positivo una fuga menor de temporización; y, sobre todo, (ii) el brazo retenido sube el ReT medio *en parte favoreciendo al producto mayoritario*, degradando el servicio del minoritario por debajo del margen de equidad. Es la **misma forma que hallamos en Program O**: la conversión *media* es real; la conversión *conjuntamente segura* no está establecida.

7.4. Qué abre esto

El STOP es correcto y **no autoriza entrenar ninguna red**. Pero define con precisión la próxima pregunta: el “residual convertible” aquí *no es de magnitud* (la magnitud sobra: +0,066), sino de **seguridad conjunta**. La pregunta defendible es: *¿puede un controlador retenido consciente de restricciones o un híbrido learning-augmented MPC mantener la ganancia media de*

+0,066 *SIN el costo de peor-producto/no-resueltos?* Si un híbrido con *gate* de confianza captura esa ganancia respetando la equidad, ahí está el paper fuerte.

8. La carrera honesta: el “cuándo NO entrenar”

Una parte esencial del programa es lo que *no* funcionó, documentado con la misma disciplina que lo que sí. A lo largo de la carrera abrimos y cerramos muchos frentes (variantes de riesgo, prevención, reordenamiento, perecederos, timing endógeno, atlas de estrés de guerra), y casi todos terminaron en **STOP** bien fundamentados: había “oportunidad clarividente” ($H_{PI} > 0$) pero *no* se convertía en ventaja observable, o el controlador estructurado ya capturaba todo el valor. El patrón recurrente:

El aprendizaje por refuerzo no está justificado cuando el control estructurado ya se sienta en la frontera observable. Saber cuándo NO entrenar es, en sí mismo, un resultado.

Esta honestidad tiene tres pilares metodológicos, todos vinculantes:

1. **Seeds selladas de un solo tiro** con contrato y criterios congelados *antes* de abrirlas (no se puede pescar el resultado favorable).
2. **Verificación adversarial (A11)**: cada afirmación se comprueba contra el artefacto real. Dos agentes se auditan mutuamente; varias sobre-afirmaciones (mías y del colaborador) fueron atrapadas y corregidas incluida esta misma semana.
3. **Métrica intacta**: la ReT canónica nunca se cambia (0/47 546); las mejoras deben pasar guardrails de recursos, servicio y equidad, no comprarse con trampa.

9. Estado actual y ruta

Trabajamos en dos carriles paralelos.

Carril A publicar Submission A / Paper 2 (Program Q). Listo en lo esencial: el marco de 4 niveles, la frontera exacta, la equivalencia $RL \approx MPC$ robusta a 5 pruebas, el mecanismo belief-insensitive y el benchmark de latencia (que retira honestamente el argumento de amortización). Destino *Computers & Industrial Engineering*. Es la publicación asegurada antes de la graduación.

Carril B Q-R1 y el intento de ganarle limpio al MPC. La secuencia disciplinada, acordada tras varias rondas de auto-crítica adversarial, es:

1. Adjudicar la confirmación canónica de Q-R1 (**hecho**: STOP con efecto real pero no conjuntamente seguro).
2. Congelar el mejor comparador estructurado *probado* (nunca llamarlo “MPC óptimo”).
3. Medir el residual con full-cohort, CRN independiente de la política, restricciones completas y auditoría de potencia con SESOI +0,01 *sin umbrales arbitrarios*.
4. Solo si queda residual: probar un *learning-augmented MPC* (valor terminal aprendido y/o corrección de creencia), con RecurrentPPO puro como *ablación*, no como candidato.
5. Si no hay residual estacionario: sensibilidad *learner-blind* de los riesgos existentes; y solo si son inertes, una extensión de riesgo acoplado a producto **validada físicamente por Garrido**, con física y grilla congeladas antes de cualquier RL.

La apuesta más prometedora *no* es más ajuste de PPO estacionario, sino **un encoder de contexto causal retenido + un MPC factible, bajo riesgos persistentes específicos por producto físicamente validados** donde una red puede aprender una representación más rica que el filtro discreto actual, siempre que el MPC reciba exactamente la misma historia.

Qué significa “ganarle al MPC”, con honestidad. No existe un teorema de imposibilidad ni un MPC óptimo certificado. “Ganarle” significa ganarle a *la familia MPC retenida más fuerte que hayamos congelado y probado* bajo el mismo contrato de información, servicio y recursos y el candidato final sería, él mismo, un *learning-augmented MPC*. Sabemos que existe una *incertidumbre física históricamente aprendible* (el efecto retenido de +0,066); no sabemos aún si un controlador justo deja un residual convertible *y seguro*. Esa medición, no más PPO, es el próximo paso.

10. Limitaciones honestas

- **Entorno estacionario y extensión de investigación.** La equivalencia $RL \approx MPC$ se demostró sin riesgos activos y con una extensión de dos productos *definida por nosotros*, no estimada de la cadena militar real. Bajo riesgos físicamente relevantes la respuesta podría cambiar.
- **El efecto retenido no es conjuntamente seguro.** +0,066 de ReT medio, pero con costo de peor-producto y no-resueltos; no es desplegable tal cual.
- **No hay óptimo de control certificado.** El MPC es un controlador aproximado de horizonte deslizante; que su creencia sea óptima para *inferencia* no prueba que sea óptimo para *control*.
- **Validación física pendiente.** Cualquier extensión de riesgo acoplado a producto requiere validación escrita de Garrido antes de ejecutarse.

11. Resumen ejecutivo en una página

- Reconstruimos, con fidelidad exacta (0/47 546), una cadena de suministro militar de 13 operaciones y su métrica de resiliencia ReT.
- Construimos un marco de falsación de 4 niveles con una **frontera de lazo abierto exacta de 65 536 planes** como clave de respuestas.
- **Logro 1 (Submission A):** el RL aprende control de lazo cerrado real le gana a las 65 536 políticas fijas (+0,07 a +0,12) pero **empata al MPC** ($\Delta_N \approx 0$, equivalencia TOST, robusta a 5 pruebas); y el MPC es además $\sim 7\times$ más rápido. Entrega el puente lazoabierto→lazo cerrado de Garrido y aporta un protocolo de decisión “cuándo entrenar”.
- **Logro 2 (Q-R1):** la retención de conocimiento entre campañas **mejora causalmente la resiliencia de arranque en frío** (+0,066, LCB +0,052, dosis-respuesta perfecta, anti-oráculo correcto), confirmada prospectivamente en seeds selladas el aprendizaje acumulado de Garrido. *Pero* aún no es conjuntamente segura (costo de equidad de producto).
- **Estrella polar restante:** un híbrido learning-augmented MPC que capture esa ganancia *sin* el costo de servicio, o bien un certificado honesto de frontera. La disciplina seeds selladas, verificación adversarial, métrica intacta es lo que hace creíbles tanto los “sí” como los “no”.